

SISTEMA DE LOCALIZAÇÃO PARA AMBIENTES FECHADOS BASEADO NA INTENSIDADE DE SINAL RECEBIDO EM REDE ZIGBEE®

VALMIR ANTONIO SCHNEIDER JUNIOR¹, RODRIGO VAREJÃO ANDREÃO², REGINALDO BARBOSA NUNES³

1. *Departamento de Engenharia Elétrica, Universidade Federal do Espírito Santo*
Av. Fernando Ferrari, 514, Goiabeiras, Vitória, ES
E-mail: valmirasj@hotmail.com
2. *Coordenadoria de Engenharia Elétrica, Instituto Federal do Espírito Santo*
Av. Vitória, 1729, Jucutuquara, Vitória, ES
E-mail: rodrigova@ifes.edu.br
3. *Coordenadoria de Engenharia Elétrica, Instituto Federal do Espírito Santo*
Av. Vitória, 1729, Jucutuquara, Vitória, ES
E-mail: regisbn@ifes.edu.br

Abstract— This article describes a location system devoted to indoor environments based on the received strength signal information (RSSI). The approach consists in generating a map with the signal strength (fingerprinting) in different locations (coordinates) of the environment. The signal strength measurements from a mobile device are obtained with regard to the fixed devices in a ZigBee® wireless network. A significant set of experiments has been carried out considering different number of fixed devices and classification methods. The experiments of the proposed system with only three fixed devices achieved a location error from zero to two meters in 92% of the tests against 80% of the tests using only two fixed devices, i.e., we obtained a low location error with few fixed devices. A performance improvement of 10% was achieved when the information of previous location was employed in the final decision.

Keywords— Location Systems, RSSI, ZigBee®

Resumo— Este artigo apresenta o estudo e implementação de um sistema de localização para ambientes fechados baseado na informação de intensidade de sinal recebido (RSSI). A técnica consiste em criar um mapa de propagação (*fingerprinting*) que representa as intensidades de sinal recebidas em diversas coordenadas do cenário de testes. As medidas de intensidade de sinal recebido do móvel se dão em relação a dispositivos instalados em pontos fixos do ambiente em uma rede sem fio baseada na tecnologia ZigBee®. Um conjunto significativo de experimentos foi realizado em um ambiente de 100m² considerando diferentes arranjos de dispositivos fixos e técnicas de classificação. Os experimentos do sistema alcançaram um erro de localização de até 2 metros em 92% dos testes usando apenas três dispositivos fixos contra 80% usando dois dispositivos fixos, ou seja, foi possível atingir um elevado desempenho para o conjunto reduzido de dispositivos fixos. Vale destacar a proposta de uma estratégia de localização por cômodo que leva em consideração a memória das localizações anteriores na decisão, produzindo uma melhoria de 10% no desempenho do sistema.

Palavras-chave— Sistemas de Localização, RSSI, ZigBee®

1 Introdução

Em problemas de localização existem dois tipos de cenários: a localização em espaço aberto (*outdoor*) e em espaço fechado (*indoor*). Um sistema de localização em espaço aberto destina-se à localização de pessoas e objetos em ambientes exteriores, ao passo que um sistema de localização em espaço fechado tem como objetivo a localização no interior de edificações. Cada um destes sistemas apresenta características e desafios diferentes, sendo que os sistemas de localização em espaço fechado são os que, segundo (Gomes, 2008) se mostram mais difíceis de implementar devido aos complexos efeitos de propagação de sinal nesses ambientes.

O projeto de um sistema de localização em ambiente fechado normalmente deve levar em conta a área

de cobertura, a tecnologia de comunicação sem fio, o número de dispositivos fixos, e a estratégia de estimação da localização. Em (Figueredo, 2009), é apresentada uma solução usando medições de intensidade do sinal de RF recebido (RSSI) em relação a quatro estações fixas em um ambiente de 22,5m². São desenvolvidos dois algoritmos diferentes para o cálculo de localização: um que faz uso de um modelo de propagação e outro que cria um mapa de RSSIs do ambiente e utiliza uma rede neural para inferir a posição. Em (Awad, 2007), também é realizada uma abordagem utilizando RSSI com 4 estações fixas em um ambiente de 17,5m² e uma rede neural na fase de inferência. Por outro lado, em (Sugano, 2006), é apresentada uma solução que utiliza RSSI em relação a 20 estações fixas em um ambiente de 75,0m². O algoritmo de inferência de posição também se baseia nos modelos de propagação para o ambiente.

Neste trabalho, o problema da localização é abordado considerando um ambiente domiciliar inteligente capaz de informar a localização de um indivíduo em uma área de 100m². A localização do dispositivo móvel se dá através da informação da potência do sinal recebido (RSSI) pela estação móvel de cada uma das estações base, utilizando uma rede de comunicação ZigBee®. O objetivo principal é investigar uma solução de complexidade reduzida e baixo custo. Consequentemente, a metodologia implementada contou com um conjunto significativo de experimentos buscando avaliar o desempenho do sistema para um número reduzido de estações fixas. A técnica de inferência da posição baseada na rede neural é comparada com a técnica dos k-vizinhos mais próximos fazendo uso do erro de localização percentual. Vale destacar a avaliação de uma estratégia de localização por cômodo do domicílio que leva em consideração a memória das localizações anteriores na decisão final.

2 Materiais e Métodos

2.1 Tecnologia ZigBee®

A tecnologia ZigBee® surgiu a partir de um consórcio de oito empresas com o propósito de criação de um protocolo para redes de sensores *wireless* baseado no padrão IEEE 802.15.4 (Heile, 2005). Este protocolo foi desenvolvido especialmente para ser utilizado em aplicações de controle e acionamento de dispositivos. O fator decisivo para a escolha de dispositivos ZigBee® para o projeto desenvolvido está no fato dos módulos permitirem acesso facilitado à informação de RSSI e no fato deste padrão ter sido desenvolvido focado para aplicações de controle e automação, sendo assim, a utilização desta tecnologia facilita a integração com outros projetos de automação residencial e controle. A tabela 1 apresenta uma comparação entre algumas características das tecnologias ZigBee® com a Bluetooth® e permite verificar importantes aspectos que justificam a escolha.

Tabela 1. Comparação entre algumas características das tecnologias ZigBee® com a Bluetooth®

Características	Bluetooth®	ZigBee®
Arquiteturas de Rede	Estrela	Árvore, estrela, malha
Tempo de acesso à rede	3s	30ms
Corrente de transmissão	40mA	30mA

A rede foi construída de modo a apresentar 3 estações base (dispositivos ZigBee® fixos em posições predeterminadas do cenário) e uma estação móvel, conectada a um computador portátil por meio de uma placa específica.

Existem três topologias de rede que podem ser utilizadas em dispositivos ZigBee®, que são: *árvore*, *estrela* e *malha* (Daintree, 2008). A topologia utiliza-

da foi a *estrela* devido à sua simplicidade e ao fato de não haver necessidade de roteamento das estações base, conforme apresenta a figura 1. Para este trabalho, o dispositivo da estação móvel foi configurado como coordenador da rede e os das estações base como dispositivos finais.




Figura 1. Topologia de rede utilizada no projeto

O Coordenador é o dispositivo responsável por iniciar, controlar, distribuir endereços, reconhecer todos os nós e armazenar informações sobre a rede. Já os dispositivos finais podem transmitir ou receber mensagens, mas não podem realizar as operações de roteamento.

2.2 Cenário de testes

Os algoritmos de inferência de localização implementados neste projeto enquadram-se na classe dos que utilizam *fingerprints*, ou seja, eles criam uma “impressão digital” do cenário escolhido (Kaemarungsi, 2004). Por este motivo, é necessário que seja pré-estabelecido um ambiente para que sejam realizadas aquisições experimentais das intensidades de sinal recebido. O cenário de teste escolhido, ilustrado na figura 2, corresponde a uma residência com aproximadamente 100m² de área total edificada. Estabeleceu-se, então, um ponto de coleta por metro quadrado de área do ambiente. Estes pontos de coleta correspondem às interseções do *grid* (malha) de aquisição conforme ilustrado na figura. É apresentando ainda o posicionamento escolhido para as Estações Base e as identificações (etiquetas) de cada um dos 11 cômodos. Em alguns pontos do ambiente, não foi possível realizar a aquisição de sinal devido à presença de obstáculos, como camas, armários, etc.

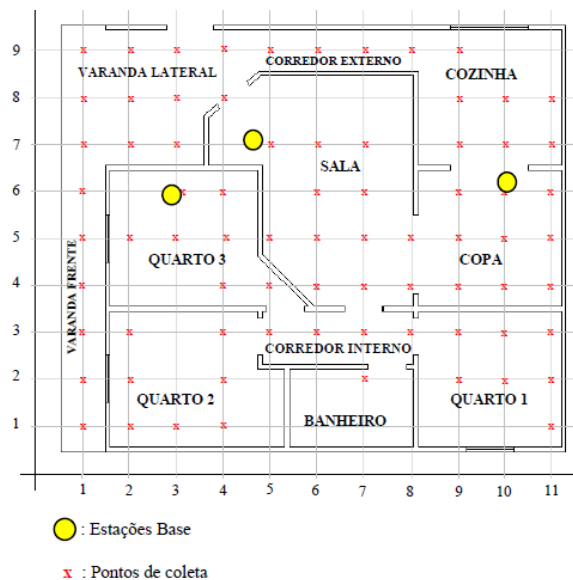


Figura 2. Cenário de testes

3.4 Aquisição dos dados

Foi desenvolvido, em linguagem C, um software para aquisição e armazenamento das informações de RSSI lidas. Este software é executado no computador portátil ligado ao dispositivo móvel. Seu princípio de funcionamento é ilustrado na figura 3, onde, um comando de solicitação de leitura de intensidade de sinal (comando *ATND*) é enviado pela estação móvel a todas as estações base que, por sua vez, respondem com a informação de RSSI, endereços e identificadores dos módulos.




Figura 3. Representação do fluxo de dados entre a estação móvel e as estações base

Com o intuito de se obter uma expressiva representação da potência do sinal recebido, determinou-se um número de 50 amostras por ponto de coleta. Posteriormente, estas amostras são divididas em conjuntos de treinamento e de testes.

3.5 Estratégias de Estimativa de Localização

A técnica adotada nesse trabalho, chamada *fingerprinting*, utiliza características eletromagnéticas observadas a partir de um determinado ponto para inferir a localização de um nó (Kaemarungsri, 2004). Sistemas de localização desse tipo possuem duas fases: uma *offline* e outra *online*. Na fase *offline*, é

construído um mapa com as intensidades dos sinais recebidos (*RSSI*) de uma determinada área, esta fase também é conhecida como fase de calibragem. Na fase *online*, um dispositivo captura o *RSSI* em uma determinada localização e compara com os valores contidos no mapa criado na fase anterior. A figura 4 ilustra as fases envolvidas no processo.




Figura 4. Representação da técnica de localização por *fingerprinting*

Para este projeto foram implementadas duas técnicas distintas para a inferência de localização: o algoritmo dos K-Vizinhos Mais Próximos (do inglês, KNN) e o das Redes Neurais Artificiais (Bahl, 2000).

K-Vizinhos Mais Próximos (KNN)

Para o algoritmo KNN escolhe-se um valor escalar para ser utilizado como representante das intensidades de sinal nos pontos de coleta, usualmente é selecionado a média ou a mediana. Em seguida, é calculada a “distância” entre o vetor de RSSI medido na fase *online* e cada *fingerprinting* armazenado na base de dados. A localização é, então, estimada baseada nos *fingerprintings* que possuem as menores distâncias. Neste caso, o termo “distância” refere-se a diferenças entre intensidades de sinal e não propriamente a uma distância física. Duas funções comumente utilizadas para cálculos de distância são a Euclidiana e a Manhattan (Nunes, 2006). Este trabalho utiliza o cálculo da distância euclidiana baseado na média como representante escalar dos valores de RSSI lidos. Devido à proximidade entre os pontos de coleta, optou-se pela utilização do método com apenas um vizinho. Sendo assim, para a estimativa será considerado somente o ponto de coleta que apresentar menor distância euclidiana. O cálculo da Distância Euclidiana é feito pela seguinte equação:

$$(1) \quad d_i = \sqrt{(I'_1 - I_{i1})^2 + (I'_2 - I_{i2})^2 + \dots + (I'_k - I_{ik})^2}$$

onde “i” identifica a Estação Base e “k” identifica o Ponto de Coleta

Além do cálculo da distância euclidiana utilizando três estações base, o procedimento foi repetido considerando apenas duas estações base. Testes com duas estações bases apresentaram taxas de acerto inferiores aos testes com três estações base. Com o intuito de aumentar o desempenho do sistema, desenvolveu-se um classificador com memória. Dessa forma, a inferência de localização realizada pelo classifi-

cador passou também a levar em consideração a estimativa de localização da estação móvel no instante anterior. Por exemplo, suponha que, em determinada experimentação, o cômodo que apresentou menor distância euclidiana para os RSSIs de teste tenha sido o *banheiro*. Considere ainda que a segunda menor distância euclidiana tenha sido para a *cozinha* e que a inferência anterior para a posição do indivíduo tenha sido a *copa*. Um classificador sem memória logo decidiria pelo cômodo com menor distância, neste caso o *banheiro*. Entretanto, um classificador com memória irá considerar o fato de que, tendo estado anteriormente na *copa*, é impossível chegar-se ao *banheiro* sem antes passar pela *sala*. Assim, o classificador com memória decidiria pelo cômodo com segunda menor distância euclidiana, neste caso a *cozinha*. Visto que um sistema com memória de percurso requer que a informação da localização anterior esteja disponível, considerou-se que, para a realização da primeira estimativa de localização, o dispositivo móvel esteja localizado próximo a uma das estações base, reduzindo-se assim os erros na estimativa inicial.

A utilização de memória de percurso, além de ser utilizada para aprimorar os resultados, pode ser utilizada para a geração de um registro do histórico do posicionamento do dispositivo móvel. Diversas aplicações práticas podem fazer uso deste histórico, por exemplo, para análises de padrões de movimentação de um paciente monitorado remotamente.

Para criação do sistema com memória elaborou-se uma matriz de pesos que considera o cômodo no instante anterior para ponderar as distâncias euclidianas calculadas. Para ajuste dos pesos dessa matriz, foram avaliadas as distâncias entre todos cômodos. Ou seja, primeiramente o algoritmo calcula a distância euclidiana entre os RSSIs medidos e os armazenados no mapa. Em seguida, para o sistema sem memória o cômodo estimado é o com menor distância euclidiana. Já para o sistema com memória, cada uma destas distâncias euclidianas calculadas é multiplicada pela matriz de pesos, fazendo com que os cômodos vizinhos à localização anterior, tenham maior influência na decisão.

Com base no mapa de radiação levantado experimentalmente, foram criados 10 percursos para testes, simulando trajetórias cotidianas de um indivíduo em sua residência. A figura 5 ilustra uma dessas trajetórias.

Rede Neural Artificial (RNA)

O classificador RNA desenvolvido utiliza uma Rede Neural que busca associar um conjunto de RSSIs de entrada com coordenadas de localização. Portanto, esta rede possui entradas, correspondentes aos valores de RSSIs medidos e duas saídas associadas às coordenadas x e y. Criou-se uma rede do tipo *feed-forward* de duas camadas com três entradas e duas saídas. Redes do tipo *feed-forward* são redes de múltiplas camadas nas quais as saídas dos neurônios se conectam somente com unidades da próxima camada

(Neves, 2006). O algoritmo de treinamento utilizado foi o de *Levenberg-Marquardt backpropagation* (Hagan, 1994). As amostras de testes e validação foram particionadas respeitando-se a proporção de 20% e 80% respectivamente. Foram realizados testes com 50, 100, 200 e 300 neurônios na camada escondida. Também foram realizados testes com três e com apenas duas estações base.




Figura 5. Representação gráfica de um dos percursos criados para testes do classificador com memória

3 Experimentos e Resultados

A figura 6 permite analisar visualmente o mapa de intensidades de sinal do ambiente. Ela apresenta uma representação cromatográfica, o que permite analisar visualmente o mapa de intensidades de sinal do ambiente.




Figura 6. Representação cromatográfica de mapa de RSSI em relação à Estação Base "B"

Para cada metro quadrado do ambiente foi atribuída uma cor correspondente à média de intensidade de sinal recebido naquele ponto de coleta em relação à estação base B. Pontos com maiores intensidades de sinal apresentam cores mais amareladas enquanto pontos com menores valores apresentam cores mais avermelhadas. Dessa forma, é fácil observar que pontos mais próximos da Estação Base B possuem maio-

res valores de RSSI, como é o caso da coordenada (3,6) (mais amarelado), e pontos mais distantes ou com muitos obstáculos tem menores valores de RSSI (mais avermelhados). Os locais de cor preta representam pontos fisicamente inacessíveis onde não foi possível realizar aquisições de RSSI. A posição da Estação Base B está assinalada por um círculo.

Para se realizar uma representação cromatográfica, em um único mapa, das intensidades de sinal recebido em cada ponto em relação às três estações base, desenvolveu-se um algoritmo onde, a cor de determinado ponto de coleta é composta por diferentes intensidades das cores primárias: vermelho, verde e azul (sistema RGB). Então, atribuiu-se a cor vermelha às intensidades de sinal em relação à estação base B, a cor azul em relação à estação base C e a cor verde em relação à estação base D. A figura 7 apresenta a representação cromatográfica obtida.




Figura 7. Representação cromatográfica do *fingerprinting* do cenário.

Esta figura é uma adequada representação visual do *fingerprinting* do cenário. Cores semelhantes em coordenadas distintas indicam que os *fingerprinting* desses dois pontos são parecidos. Assim, durante a fase de estimativa de localização, o algoritmo de inferência apresenta maior probabilidade de confundir-se entre estes pontos devido às suas similaridades.

A avaliação da precisão do sistema foi realizada calculando-se o erro na estimativa de localização. Este erro consiste na distância (em metros) entre a coordenada estimada e a posição real da estação móvel.

A figura 8 ilustra a frequência de ocorrência do erro (normalizada) para os algoritmos KNN com duas e três estações base. Percebe-se que, aproximadamente 85% das estimativas apresentaram erros menores ou iguais a 1 metro, quando se utiliza 3 estações base, contra aproximadamente 70% quando se utiliza 2 estações base.

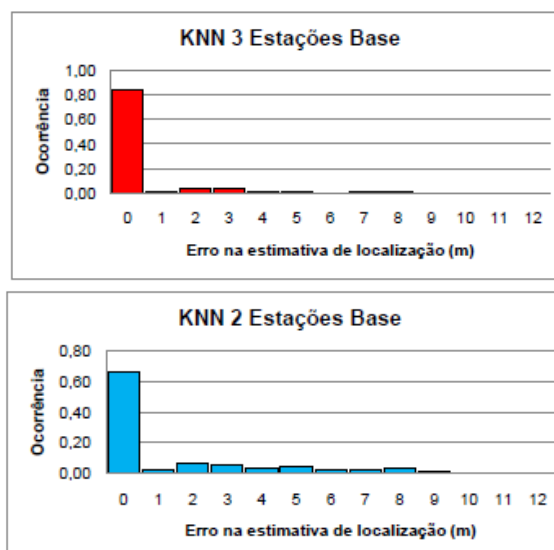


Figura 8. Histograma normalizado do erro na estimativa de localização com o classificador (a) KNN com 3 estações base e (b) KNN com 2 estações base

A frequência de ocorrência do erro para os algoritmos RNA com duas e três estações base é apresentada na figura 9. Os resultados referem-se à rede com 200 neurônios na camada escondida. Percebe-se que, aproximadamente 80% das estimativas apresentaram erros de até 1 metro, quando se utiliza 3 estações base, contra aproximadamente 55% quando se utiliza 2 estações base. A utilização de duas estações base é importante pois reduz o custo de implantação do sistema.

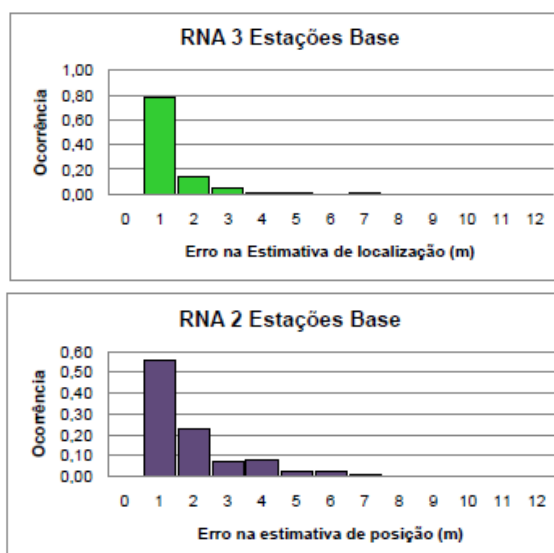


Figura 9. Histograma normalizado do erro na estimativa de localização com o classificador (a) RNA com 3 estações base e (b) RNA com 2 estações base

O gráfico da figura 10 apresenta as funções de distribuição cumulativas do erro na estimativa de localização para os classificadores do tipo RNA e KNN com duas e três estações base.

Este gráfico pode ser analisado da seguinte maneira: por exemplo, para o classificador RNA com 2 estações base, erros de estimativa menores que 2 metros são apresentados em 80% dos testes. Por outro lado, para o mesmo classificador, porém com 3 estações base, erros menores que 2 metros foram obtidos em 92% dos testes. Isso mostra a influência do número de estações base em um sistema de localização. Se forem analisados algoritmos diferentes, mas com o mesmo número de estações base, é possível perceber que, para erros menores que 1,75m, o algoritmo KNN apresentou melhor desempenho, por outro lado, se forem admitidos erros maiores que 1,75m os resultados para Rede Neural foram melhores. É importante ressaltar que estes resultados estão associados ao fato de os pontos de coleta estarem distanciados de 1 metro. Diferentes espaçamentos entre os pontos de coleta poderiam levar a diferentes resultados.

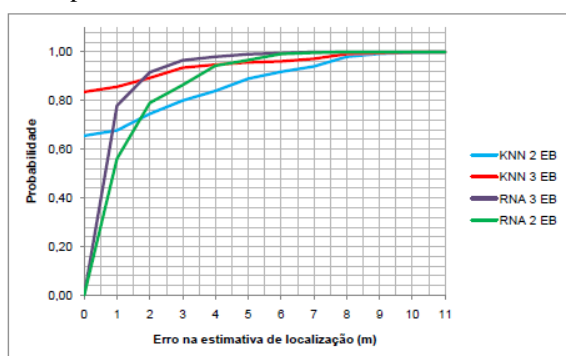


Figura 10. Distribuição cumulativa de probabilidade de erro na estimativa de posição

Por fim, a tabela 2 apresenta os resultados do sistema para duas e três estações base após ter sido implementado o algoritmo com memória de percurso para o algoritmo KNN. Os valores na tabela correspondem à taxa de acerto do cômodo, ou seja, o número de vezes que o algoritmo identificou corretamente o cômodo dividido pelo número de testes realizados.

Tabela 2. Comparação das taxas de acerto entre o sistema com e sem memória

Taxas de Acerto do Cômodo			
3 Estações Base		2 Estações Base	
Sem memória	Com memória	Sem memória	Com memória
87,63%	95,13%	70,13%	78,92%

4 Conclusão

Este trabalho teve como objetivo o desenvolvimento de um sistema de localização para ambiente fechado baseado na informação de intensidade de sinal recebido em uma rede ZigBee®. A técnica de estimativa de localização adotada consiste na análise de *fingerprinting*. Foram realizados testes em um ambiente fechado com 100m² usando tanto três quanto duas estações base (dispositivos fixos).

Para a realização da inferência de localização do dispositivo móvel, foram implementados dois tipos de algoritmos: o KNN e o com Redes Neurais Artifici-

ais. Estes algoritmos objetivam determinar a localização da estação móvel, pela comparação entre o *fingerprinting* armazenado e os valores de intensidade de sinal medidos na fase *online*. Com o intuito de aumentar a taxa de acerto, foi adicionada ao sistema desenvolvido a chamada “memória de percurso”. Isso significa que a estimativa de localização feita pelo algoritmo considera, além dos valores de RSSI medidos, a avaliação da posição anterior da estação móvel.

Os resultados comprovaram que, mesmo com a redução do número de estações fixas, a utilização de memória de percurso, permitiu uma considerável taxa de acerto.

Referências Bibliográficas

- Awad, A.; Frunzke, T.; Dressler, F. (2007). “Adaptive Distance Estimation and Localization in WSN using RSSI Measures”, 10th Euromicro Conference on Digital System Design Architectures, Methods and Tools, Alemanha.
- Bahl, P.; Padmanabhan, V. N. (2000). “Radar: An In-Building RF-Based User Location and Tracking System”, Proc. IEEE INFOCOM, vol. 2, pp. 775-784, Tel-Aviv, Israel.
- Daintree Networks (2008). “Getting Started with ZigBee and IEEE 802.15.4”, Disponível em: http://www.daintree.net/downloads/whitepapers/zigbee_primer.pdf. Acessado em 18/04/2011.
- Figueredo, L. F. C.; Couto, F. L.; Bauchspiess, A. (2009). “An Evaluation of Rssi Based Indoor Localization Systems in Wireless Sensor Networks”, IX Simpósio Brasileiro de Automação Inteligente, Brasília-DF.
- Gomes, G.L.S. “Sistema RFID com Tecnologia Zig-Bee®”, Dissertação de Mestrado, Universidade Técnica de Lisboa, Lisboa, Portugal, 2008.
- Hagan M. T.; Menhaj M. B. “Training feedforward networks with the Marquardt algorithm”. IEEE-Transactions on Neural Networks, 5 (6): 989-993, 1994.
- Heile B. (2005). “ZigBee Alliance Tutorial”. Disponível em: http://www.cs.ucdavis.edu/~aksoy/course/w06/slides/ZigBeeTutorial_05.ppt. Acesso em 01/11/2010.
- Kaemarungsi, K; Krishnamurthy, P. (2004). “Modeling of Indoor Positioning Systems Based on Location Fingerprinting”. Proc. IEEE INFOCOM., Hong Kong, China.
- Sugano, M.; Kawazoe, T. (2006). “Indoor Localization System Using RSSI Measurement of Wireless Sensor Network Based on Zigbee Standard”, Osaka University, Suita, Osaka, Japan.